

Diagnóstico y Limpieza de Datos

Establecimientos Educativos de Guatemala

Nivel Diversificado · Fuente: MINEDUC

Luis Palacios

Hugo Barillas

jose lopez



Obtención de los datos

- Sitio MINEDUC: sin API, sin posible descarga — solo un departamento a la vez
- Playwright automatizó 23 consultas (Guatemala + Ciudad Capital)



11,890

Filas extraídas

| Diagnóstico: ¿qué encontramos?

11,867

Filas

17 variables originales

1,814

similares

Posibles duplicados

7.97%

946 de 11,867 Teléfonos vacíos

14.6%

1,773 con "—" o vacío

Proporción de valores faltantesdame

Los 4 principios



N/A

Faltante no recuperable = NA explícito



Nunca fusionar automático

Duplicados se marcan, no se eliminan



Respetar categorías reales

CIUDAD CAPITAL ≠ error tipográfico



Preservar el original

Correcciones en columnas nuevas, nunca sobrescriben

La estrategia en acción

 Variable: TELÉFONO

Antes: Celda con 2 números mezclados en un solo campo

Después: TELÉFONO (8 dígitos) + columna nueva
TELÉFONO_2

 Duplicados de nombres

Antes: 1,814 pares de nombres similares sin clasificar

Después: 745 grupos marcados con RapidFuzz, 101 casos
"revisar duplicado verdadero" — ninguno fusionado

Resultado final

11,867

Registros — 0 eliminados

Toda la información original preservada

21

Variables finales

17 originales + 4 derivadas

100%

Reproducible

Scripts → notebooks → Libro de Códigos

Gracias por
ver

