

Libro de Códigos

Conjunto: Establecimientos educativos de Guatemala — nivel diversificado

Versión del conjunto limpio: 1.0

Archivo: data/establecimientos_diversificado_limpio.csv

Fecha de extracción de la fuente: 2026-07-18

Fecha de generación del conjunto limpio: 2026-07-19 (salida de notebooks/04_limpieza_fase3_telefono_duplicados_final.ipynb)

Fuente: Ministerio de Educación de Guatemala (MINEDUC) — Buscador de Establecimientos Educativos

URL: http://www.mineduc.gob.gt/BUSCAESTABLECIMIENTO_GE/

Filtro de descarga: NIVEL ESCOLAR = DIVERSIFICADO (código de nivel 46 en el sitio)

Cobertura geográfica: 23 entidades del combo del sitio (22 departamentos oficiales + CIUDAD CAPITAL como entidad separada de GUATEMALA)

Registros: 11,867 filas

Variables: 21 columnas

Este libro describe metadatos necesarios para analizar el conjunto limpio. Complementa el plan en 02_Plan_de_Limpieza.md y el registro en data/registro_transformaciones.csv.

Metadatos generales del conjunto

Campo | Valor

Nombre del dataset | establecimientos_diversificado_limpio

Formato | CSV, encoding utf-8-sig, separador coma

Unidad de observación | Un registro de autorización/establecimiento en el buscador MINEDUC (identificado por CODIGO)

Idioma de los valores | Español (mayúsculas, sin tildes en la mayoría de campos de la fuente)

Catálogo de referencia geo | data/catalogo_departamentos_municipios.csv (extraído del propio sitio)

Licencia / uso | Datos públicos gubernamentales; uso académico del curso CC3084

Resumen de columnas

| Variable | Tipo analítico | Origen | Derivada

1 | CODIGO | texto / ID | Fuente | No

2 | DISTRITO | texto | Fuente | No

3 | DEPARTAMENTO | categórica | Fuente | No

4 | MUNICIPIO | categórica | Fuente | No

5 | ESTABLECIMIENTO | texto | Fuente | No

6 | DIRECCION | texto | Fuente | No

7 | TELEFONO | texto (formato fijo) | Fuente | No

8 | TELEFONO_2 | texto (formato fijo) | Derivada | Sí

9 | SUPERVISOR | texto | Fuente | No

10 | DIRECTOR | texto | Fuente | No

11 | NIVEL | categórica | Fuente | No

12 | SECTOR | categórica | Fuente | No
13 | AREA | categórica | Fuente | No
14 | STATUS | categórica | Fuente | No
15 | MODALIDAD | categórica | Fuente | No
16 | JORNADA | categórica | Fuente | No
17 | PLAN | categórica | Fuente | No
18 | DEPARTAMENTAL | categórica / texto controlado | Fuente | No
19 | POSIBLE_DUPLICADO_GRUPO | ID de clúster | Derivada | Sí
20 | NOTA_DUPLICADO | texto de triage | Derivada | Sí
21 | ARCHIVO_ORIGEN | metadato técnico | Consolidación | No*

*No es variable del fenómeno educativo; es metadato de trazabilidad agregado al consolidar los CSV crudos.

Diccionario variable por variable

Para cada variable se documentan: descripción, tipo de dato, dominio permitido, valores posibles (cuando aplica), tratamiento de limpieza, y si es derivada.

1. CODIGO

Campo | Contenido

Descripción | Identificador único del establecimiento en el buscador MINEDUC

Tipo de dato | Texto (string). No convertir a numérico

Dominio permitido | Patrón `##-##-####-##` (dos dígitos – dos – cuatro – dos). El último bloque 46 corresponde al nivel diversificado en la fuente

Valores posibles | 11,867 códigos distintos (uno por fila)

Tratamiento | Sin transformación de contenido; verificación de patrón y unicidad

Derivada | No

Faltantes | No admite NA en el conjunto limpio

2. DISTRITO

Campo | Contenido

Descripción | Código o etiqueta de distrito escolar asociado al establecimiento

Tipo de dato | Texto libre semi-estructurado

Dominio permitido | Cualquier cadena no vacía tras normalización; o NA

Valores posibles | Múltiples formatos coexisten (ej. 01-01-0026, 01-102). No se forzó un único patrón

Tratamiento | Trim, colapso de espacios, vacíos → NA

Derivada | No

Faltantes | 532 (~4.5%)

3. DEPARTAMENTO

Campo | Contenido

Descripción | Entidad geográfica según el combo del sitio MINEDUC

Tipo de dato | Categórica (category en pandas; texto en CSV)

Dominio permitido | Valores del catálogo del sitio (23 entidades)

Valores posibles | ALTA VERAPAZ, BAJA VERAPAZ, CHIMALTENANGO, CHIQUIMULA, CIUDAD CAPITAL, EL PROGRESO, ESCUINTLA, GUATEMALA, HUEHUETENANGO, IZABAL, JALAPA, JUTIAPA, PETEN, QUETZALTENANGO, QUICHE, RETALHULEU, SACATEPEQUEZ, SAN MARCOS, SANTA ROSA, SOLOLA, SUCHITEPEQUEZ, TOTONICAPAN, ZACAPA

Tratamiento | Trim + mayúsculas; validación contra catálogo. Se mantienen CIUDAD CAPITAL y GUATEMALA separados

Derivada | No

Faltantes | 0

4. MUNICIPIO

Campo | Contenido

Descripción | Municipio (o zona capitalina) del establecimiento

Tipo de dato | Categórica / texto controlado

Dominio permitido | Par (DEPARTAMENTO, MUNICIPIO) debe existir en data/catalogo_departamentos_municipios.csv

Valores posibles | 352 valores distintos en el limpio (incluye zonas de Ciudad Capital, ej. ZONA 1 ...)

Tratamiento | Trim + mayúsculas; validación del par completo

Derivada | No

Faltantes | 0

5. ESTABLECIMIENTO

Campo | Contenido

Descripción | Nombre del establecimiento educativo

Tipo de dato | Texto

Dominio permitido | Texto no vacío tras limpieza; o NA

Valores posibles | Texto libre (5,778 nombres distintos)

Tratamiento | Colapso de espacios; remoción de comillas decorativas con regla automática + correcciones manuales documentadas; se preservan apóstrofes ortográficos legítimos

Derivada | No

Faltantes | Mínimos (celdas vacías originales)

6. DIRECCION

Campo | Contenido

Descripción | Dirección física reportada

Tipo de dato | Texto

Dominio permitido | Texto libre; o NA

Valores posibles | Texto libre

Tratamiento | Espacios; mayúsculas; abreviaturas Z.→ZONA, AV.→AVENIDA, CALZ.→CALZADA, KILOMETRO/KM→KM.; placeholders → NA

Derivada | No

Faltantes | 82 (vacíos + placeholders)

7. TELEFONO

Campo | Contenido

Descripción | Teléfono principal del establecimiento

Tipo de dato | Texto con formato fijo

Dominio permitido | NNNN-NNNN (exactamente 8 dígitos) o NA

Valores posibles | Números de 8 dígitos formateados; no se validó operador ni prefijo geográfico más allá de longitud

Tratamiento | Extracción de dígitos; rechazo de letras / longitudes ≠ 8; formato NNNN-NNNN

Derivada | No

Faltantes | 1,052

8. TELEFONO_2 (derivada)

Campo | Contenido

Descripción | Segundo teléfono cuando la celda original de TELEFONO contenía más de un número válido

Tipo de dato | Texto con formato fijo

Dominio permitido | NNNN-NNNN o NA

Valores posibles | Igual que TELEFONO

Tratamiento / cálculo | Se toma el segundo bloque de 8 dígitos válido hallado en la celda cruda de teléfono

Utilidad | Evita descartar un contacto real que venía concatenado en un solo campo

Derivada | Sí

Faltantes | Alta (solo se llena cuando existía segundo número; 121 registros afectados en el log de transformación)

9. SUPERVISOR

Campo | Contenido

Descripción | Nombre del supervisor reportado

Tipo de dato | Texto

Dominio permitido | Texto libre o NA

Valores posibles | Texto libre

Tratamiento | Espacios; vacíos → NA; sin imputación

Derivada | No

Faltantes | 535

10. DIRECTOR

Campo | Contenido

Descripción | Nombre del director reportado

Tipo de dato | Texto

Dominio permitido | Texto libre o NA

Valores posibles | Texto libre

Tratamiento | Espacios; vacíos y placeholders (--, SIN DATO, -, ., etc.) → NA; sin imputación

Derivada | No

Faltantes | ~1,831 (vacíos + placeholders marcados)

11. NIVEL

Campo | Contenido

Descripción | Nivel educativo del registro

Tipo de dato | Categórica

Dominio permitido | Exactamente DIVERSIFICADO

Valores posibles | DIVERSIFICADO

Tratamiento | Normalización defensiva + casteo a category

Derivada | No

12. SECTOR

Campo | Contenido

Descripción | Sector institucional

Tipo de dato | Categórica

Dominio permitido | Conjunto cerrado

Valores posibles | COOPERATIVA, MUNICIPAL, OFICIAL, PRIVADO

Tratamiento | Normalización + category

Derivada | No

13. AREA

Campo | Contenido

Descripción | Área geográfica de ubicación (urbana/rural)

Tipo de dato | Categórica

Dominio permitido | Conjunto cerrado

Valores posibles | RURAL, SIN ESPECIFICAR, URBANA

Tratamiento | Normalización + category. SIN ESPECIFICAR no se convierte a NA

Derivada | No

14. STATUS

Campo | Contenido

Descripción | Estado operativo / administrativo del establecimiento

Tipo de dato | Categórica

Dominio permitido | Conjunto cerrado

Valores posibles | ABIERTA, CERRADA DEFINITIVAMENTE, CERRADA TEMPORALMENTE, TEMPORAL NOMBRAMIENTO, TEMPORAL TITULOS

Tratamiento | Normalización + category

Derivada | No

15. MODALIDAD

Campo | Contenido

Descripción | Modalidad lingüística
Tipo de dato | Categórica
Dominio permitido | Conjunto cerrado
Valores posibles | BILINGUE, MONOLINGUE
Tratamiento | Normalización + category
Derivada | No

16. JORNADA

Campo | Contenido
Descripción | Jornada de atención
Tipo de dato | Categórica
Dominio permitido | Conjunto cerrado
Valores posibles | DOBLE, INTERMEDIA, MATUTINA, NOCTURNA, SIN JORNADA, VESPERTINA
Tratamiento | Normalización + category. SIN JORNADA no se convierte a NA
Derivada | No

17. PLAN

Campo | Contenido
Descripción | Plan o modalidad de estudio
Tipo de dato | Categórica
Dominio permitido | 13 categorías de la fuente (sin unificación)
Valores posibles | A DISTANCIA, DIARIO(REGULAR), DOMINICAL, FIN DE SEMANA, INTERCALADO, IRREGULAR, MIXTO, SABATINO, SEMIPRESENCIAL, SEMIPRESENCIAL (DOS DIAS A LA SEMANA), SEMIPRESENCIAL (FIN DE SEMANA), SEMIPRESENCIAL (UN DIA A LA SEMANA), VIRTUAL A DISTANCIA
Tratamiento | Normalización + category; no se colapsaron variantes de SEMIPRESENCIAL
Derivada | No

18. DEPARTAMENTAL

Campo | Contenido
Descripción | Dirección / dependencia departamental reportada por la fuente
Tipo de dato | Texto controlado (26 valores)
Dominio permitido | Valores observados tras normalización
Valores posibles | Incluye, entre otros: GUATEMALA NORTE, GUATEMALA SUR, GUATEMALA ORIENTE, GUATEMALA OCCIDENTE, y nombres por departamento (algunos con tilde según la fuente, ej. PETÉN, QUICHÉ)
Tratamiento | Trim + mayúsculas + colapso de espacios
Derivada | No

19. POSIBLE_DUPLICADO_GRUPO (derivada)

Campo | Contenido
Descripción | Identificador de clúster de posibles duplicados parciales por similitud de nombre

Tipo de dato | Texto / entero como string; NA si la fila no pertenece a ningún clúster
Dominio permitido | Entero de grupo ≥ 1 , o vacío/NA
Valores posibles | 745 grupos; 2,947 filas marcadas
Cálculo | RapidFuzz token_sort_ratio ≥ 90 entre nombres dentro del mismo municipio; agrupación en clústeres
Utilidad | Facilitar revisión humana sin borrar filas
Derivada | Sí
Detalle auxiliar | data/revision_posibles_duplicados.csv

20. NOTA_DUPLICADO (derivada)

Campo | Contenido
Descripción | Nota de triage sobre el tipo de posible duplicado
Tipo de dato | Texto
Dominio permitido | Combinaciones de etiquetas de triage; o vacío/NA
Valores posibles (etiquetas base) |
| NO ES DUPLICADO: mismo colegio con jornada/plan distintos (autorización legítima independiente)
| REVISAR: nombre muy similar, confirmar manualmente
| REVISAR: posible duplicado verdadero (nombre, dirección, jornada y plan coinciden)
| (pueden concatenarse con | cuando aplican varias)
Utilidad | Documentar la decisión analítica sin eliminar registros
Derivada | Sí

21. ARCHIVO_ORIGEN (metadato técnico)

Campo | Contenido
Descripción | Nombre del CSV crudo por departamento del que proviene la fila
Tipo de dato | Texto
Dominio permitido | Uno de los 23 archivos en data/raw/
Valores posibles | Ej. 00_CIUDAD_CAPITAL_DIVERSIFICADO.csv, 01_GUATEMALA_DIVERSIFICADO.csv, ...
Tratamiento | Sin cambios
Derivada | No (metadato de pipeline, no del fenómeno)
Fuente / versión | Agregado por scripts/01_consolidar_crudo.py

Tratamiento global de valores especiales

Caso | Tratamiento en el limpio
NA / celda vacía / solo espacios | NA (celda vacía en CSV)
N/A, NULL, -, ., SIN DATO, -- | NA (donde se aplicó la lista de placeholders)
Espacios iniciales/finales / múltiples | Eliminados / colapsados
Duplicados exactos | No había; se valida que sigan en 0
Duplicados parciales | Marcados, no eliminados

Control de versiones del conjunto

Cualquier regeneración del CSV debe actualizar este número de versión y la fecha en este libro.

Cómo citar / reproducir

1. Clonar el repositorio.
2. Instalar dependencias (requirements.txt).
3. Ejecutar notebooks 01→04 en orden (o partir de los CSV ya generados en data/).
4. El artefacto analítico principal es data/establecimientos_diversificado_limpio.csv descrito por este libro.